

Maestría en Ciencia de Datos y Analítica

Proyecto Integrador II

**Estimación del volumen de agua de
Guatapé
mediante redes neuronales y series de
tiempo**

Alejandro Silva

Dilan Monsalve

Franco Garcés

Isabel Jurado

Juan David Trujillo

Índice

1. Introducción	3
2. Marco Teórico	3
2.1. Series de tiempo	3
2.2. Modelos estadísticos implementados	4
2.3. Redes Neuronales Recurrentes y LSTM	4
2.4. Redes Neuronales Convolucionales	5
2.5. Índice Normalizado de Diferencia de Agua (NDWI)	5
2.6. Métricas de evaluación	5
3. Desarrollo Metodológico	6
3.1. Problema	6
3.2. Datos	7
3.3. Análisis Exploratorio de Datos (EDA)	7
3.4. Modelado	8
3.4.1. Red Neuronal Convolutacional (exploración descartada)	8
3.4.2. Red Neuronal Recurrente LSTM	8
3.4.3. Métodos Estadísticos	9
4. Tecnología — Sistemas de Aprendizaje Automático (MLOps)	10
4.1. Datos	10
4.2. Procesamiento	10
4.3. Entrenamiento	10
4.4. Almacenamiento	10
4.5. Despliegue	11
4.6. Aplicación	11
5. Resultados	11
5.1. Red Neuronal Convolutacional sobre imágenes Sentinel-2	11
5.2. Modelos estadísticos	12
5.3. Red Neuronal Recurrente LSTM	12

6. Conclusiones

13

1. Introducción

La gestión eficiente de los recursos hídricos representa uno de los principales desafíos para el sector energético colombiano, especialmente debido a la alta dependencia de la generación hidroeléctrica dentro de la matriz energética nacional. En este contexto, el embalse de El Peñol-Guatapé se posiciona como una infraestructura estratégica, ya que su nivel de almacenamiento de agua influye directamente en la capacidad de generación eléctrica, la estabilidad del sistema y la toma de decisiones operativas relacionadas con la prevención de riesgos asociados a sequías, vertimientos o desbordamientos.

Actualmente, la medición del volumen útil y del nivel del embalse se realiza principalmente mediante sensores físicos y estaciones hidrométricas que, aunque ofrecen información confiable, presentan limitaciones importantes: altos costos de instalación y mantenimiento, vulnerabilidad ante fallas técnicas, cobertura espacial reducida y posibles interrupciones en la recolección de datos. Estas dificultades evidencian la necesidad de desarrollar soluciones complementarias que permitan fortalecer el monitoreo continuo y mejorar la precisión en la estimación del comportamiento hídrico del embalse.

El presente proyecto propone abordar este problema mediante técnicas de aprendizaje automático aplicadas a los datos históricos de volumen útil diario reportados por XM, el operador del sistema eléctrico colombiano, a través de su API pública. El modelo central del proyecto es una red neuronal recurrente de tipo LSTM (*Long Short-Term Memory*), entrenada sobre la serie temporal histórica del embalse para predecir el volumen útil con horizontes de 7, 15 y 30 días. Como componente estadístico comparativo, se implementaron tres modelos clásicos: ARMA sobre retornos logarítmicos, ARMA-GARCH(1,1) y Holt-Winters con estacionalidad aditiva.

Como parte del proceso de investigación, el proyecto exploró adicionalmente el uso de imágenes satelitales Sentinel-2 obtenidas desde la plataforma Copernicus. La hipótesis era que el área superficial del espejo de agua calculada mediante el NDWI podría enriquecer la estimación del nivel. Sin embargo, esta línea encontró limitaciones fundamentales de naturaleza conceptual y operacional; los modelos no produjeron resultados satisfactorios y el enfoque fue descartado.

El objetivo principal es diseñar e implementar un sistema predictivo basado en series de tiempo, desplegado en AWS con prácticas de MLOps y DataOps que garantizan escalabilidad, trazabilidad y replicabilidad del pipeline completo.

2. Marco Teórico

2.1 Series de tiempo

Una serie de tiempo es un conjunto de observaciones registradas secuencialmente a lo largo del tiempo, cuyo análisis permite identificar patrones, tendencias, estacionalidades

y comportamientos cíclicos subyacentes [3]. Los métodos clásicos incluyen los modelos AR, MA y ARIMA. Cuando la serie original no es estacionaria pero sus retornos logarítmicos sí lo son, el análisis se realiza sobre la serie transformada y los resultados se reconvierten al nivel original.

2.2 Modelos estadísticos implementados

ARMA sobre retornos logarítmicos

El modelo ARMA(p, q) se aplicó sobre los retornos logarítmicos diarios

$$r_k = \log(V_k) - \log(V_{k-1}), \quad (1)$$

que estabilizan la varianza y convierten la serie no estacionaria en estacionaria. La selección de órdenes se realizó mediante ACF/PACF y búsqueda automática por criterio AIC con la librería `pmdarima`.

ARMA-GARCH(1,1)

Los residuos del ARMA exhiben heteroscedasticidad condicional con curtosis extremadamente elevada. Se empleó GARCH(1,1) acoplado al componente de media:

$$\sigma_k^2 = \omega + \alpha \varepsilon_{k-1}^2 + \beta \sigma_{k-1}^2, \quad (2)$$

con distribución t -Student para modelar colas pesadas [7].

Holt-Winters (ETS)

Variante aditiva con estacionalidad de 365 períodos, aplicada directamente sobre la serie en niveles. Parámetros (α, β, γ) estimados por optimización numérica [8]. Genera pronósticos de 7, 15 y 30 días con intervalos de confianza del 95 %.

2.3 Redes Neuronales Recurrentes y LSTM

Las redes LSTM resuelven el problema del gradiente evanescente de las RNN clásicas mediante un mecanismo de tres compuertas [6]. Cada unidad mantiene el estado de celda c_k (memoria de largo plazo) y el estado oculto h_k :

$$f_k = \sigma(W^f \cdot [h_{k-1}, x_k] + b^f) \quad (3)$$

$$i_k = \sigma(W^i \cdot [h_{k-1}, x_k] + b^i) \quad (4)$$

$$c_k = f_k \odot c_{k-1} + i_k \odot \tanh(W^c \cdot [h_{k-1}, x_k] + b^c) \quad (5)$$

$$o_k = \sigma(W^o \cdot [h_{k-1}, x_k] + b^o) \quad (6)$$

$$h_k = o_k \odot \tanh(c_k) \quad (7)$$

Este mecanismo permite retener información a lo largo de cientos de pasos temporales, adecuado para series hidrológicas donde el volumen actual refleja meses de precipitación acumulada y ciclos estacionales.

2.4 Redes Neuronales Convolucionales

Las CNN extraen características mediante convolución discreta y activaciones ReLU. En este proyecto se exploraron para estimar el nivel del embalse desde imágenes Sentinel-2 procesadas con NDWI. El enfoque fue descartado por limitaciones descritas en las secciones 3.4.1 y 5.1.

2.5 Índice Normalizado de Diferencia de Agua (NDWI)

$$\text{NDWI} = \frac{B_{03} - B_{08}}{B_{03} + B_{08}}, \quad (8)$$

donde B_{03} es la banda verde y B_{08} la de infrarrojo cercano de Sentinel-2. Captura el área superficial en km^2 pero no el volumen almacenado, que depende de la batimetría específica de cada embalse.

2.6 Métricas de evaluación

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (9)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (10)$$

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (11)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (12)$$

3. Desarrollo Metodológico

Metodología

Se utiliza la metodología TDSP (*Team Data Science Process*), equivalente a combinar CRISP-DM con métodos ágiles como SCRUM [5]:

- **Entendimiento del negocio.** Definición del problema, fuentes de datos y variable objetivo.
- **Adquisición y entendimiento de los datos.** Ingesta desde la API de XM y verificación de usabilidad.
- **Modelado.** Entrenamiento y evaluación de modelos.
- **Despliegue.** Implementación en AWS con prácticas de MLOps y DataOps.
- **Aceptación del cliente.** Entrega del documento, presentación y demostración del pipeline.

3.1 Problema

Problema del negocio

Colombia genera cerca del 70 % de su electricidad en centrales hidroeléctricas. El embalse de Guatapé, en Antioquia, es uno de los principales reservorios del sistema energético nacional. Los sensores físicos actuales presentan limitaciones de costo, mantenimiento y discontinuidades. El proyecto propone un sistema predictivo basado en series de tiempo y aprendizaje profundo desplegado en AWS.

Impacto de la solución

- **Mejora en la precisión del monitoreo:** estimaciones continuas del volumen útil reduciendo la dependencia de sensores físicos.
- **Reducción de costos:** la API pública de XM es de acceso gratuito.
- **Apoyo a decisiones estratégicas:** predicciones a 7, 15 y 30 días para planificación de generación y prevención de riesgos.
- **Escalabilidad:** arquitectura AWS adaptable a otros embalses con mínimas modificaciones.

3.2 Datos

Dataset 1: Serie temporal de volumen útil — API de XM (dataset principal)

Registros diarios del volumen útil del embalse de El Peñol-Guatapé obtenidos mediante `pydataxm` desde la API de XM, desde 2015 hasta la fecha de ejecución. **Variables:** *Date* (fecha), *Name* (embalse), *Value* (volumen útil en m^3 — variable objetivo). **¿Pública?:** Sí.

Dataset 2: Imágenes satelitales Sentinel-2 (exploración descartada)

541 imágenes NDWI de nueve embalses colombianos etiquetadas con porcentaje de llenado de XM. Los resultados no fueron satisfactorios y este dataset no forma parte del pipeline final. **Variables:** Imagen (GeoTIFF B_{03}/B_{08} , 10 m/píxel), Etiqueta (% llenado). **¿Pública?:** Sí, Copernicus Data Space.

3.3 Análisis Exploratorio de Datos (EDA)

Entendimiento de los datos

La serie abarca aproximadamente 4.200 observaciones diarias desde 2015. Se verificó el rango temporal, la frecuencia de actualización y la ausencia de valores inválidos.

Preparación y limpieza

Ordenamiento cronológico, eliminación de duplicados e interpolación lineal de valores faltantes.

Análisis descriptivo

La serie presenta ciclos anuales marcados: llenado entre marzo y junio, descarga entre julio y febrero. La prueba ADF no rechaza raíz unitaria en niveles ($p \geq 0,05$) pero sí en retornos logarítmicos ($p < 0,05$), validando la transformación para los modelos estadísticos.

Identificación de patrones relevantes

El análisis ACF/PACF de los retornos informa la selección de órdenes ARMA. Los residuos presentan curtosis > 200 y heteroscedasticidad condicional, motivando el uso de GARCH. La estacionalidad anual motiva Holt-Winters con período de 365.

3.4 Modelado

- *Estadística avanzada* — ARMA, ARMA-GARCH(1,1) y Holt-Winters para forecasting comparativo.
- *Aprendizaje profundo* — Red LSTM sobre serie temporal. CNN sobre imágenes Sentinel-2 explorada y descartada.
- *Sistemas de aprendizaje automático* — Pipeline completo en AWS con ingesta, procesamiento, entrenamiento e inferencia automatizados.

3.4.1 Red Neuronal Convolutiva (*exploración descartada*)

EfficientNet-B0 entrenado con *fine-tuning* sobre 541 imágenes NDWI etiquetadas con porcentaje de llenado. Resultado: R^2 negativo. El diagnóstico completo se presenta en la sección 5.1.

3.4.2 Red Neuronal Recurrente LSTM

Preparación de los datos

La serie se curó (orden cronológico, deduplicación, interpolación lineal) y se dividió temporalmente 80/20 sin aleatorización. Normalización con `MinMaxScaler` ajustado solo sobre el conjunto de entrenamiento. Muestras con ventana deslizante de 30 días de entrada; predicción iterativa para horizontes de 7, 15 y 30 días.

Arquitectura e hiperparámetros

Dos capas LSTM apiladas (64 y 32 unidades), *dropout* 0.2, capa densa de salida. Función de pérdida MSE, optimizador Adam, máximo 200 épocas con *early stopping* (paciencia 20) y `ReduceLROnPlateau`, lotes de 32. Implementado en TensorFlow/Keras. Intervalos de confianza al 95 % estimados mediante Monte Carlo Dropout con 200 trayectorias.

Estrategia de entrenamiento

Al finalizar cada época se evalúa la pérdida de validación y se guarda el modelo solo si mejora. Al concluir se carga automáticamente el mejor *checkpoint*.

Cuadro 1: Hiperparámetros del modelo LSTM

Hiperparámetro	Valor
Capas LSTM	2
Unidades por capa	[64, 32]
Dropout	0.2
Ventana de entrada	30 días
Horizonte de predicción	7 / 15 / 30 días
Función de pérdida	MSE
Optimizador	Adam
Tasa de aprendizaje	1×10^{-3}
Batch size	32
Épocas máximas	200
Early stopping (paciencia)	20 épocas

3.4.3 Métodos Estadísticos

Prueba de estacionariedad

ADF confirma que la serie en niveles no es estacionaria ($p \geq 0,05$) pero los retornos logarítmicos sí ($p < 0,05$), validando la transformación de la ecuación (1).

Modelo ARMA

Órdenes seleccionados por ACF/PACF y criterio AIC con `auto_arima`. Pronóstico reconvertido al nivel original mediante acumulación exponencial.

Modelo ARMA-GARCH(1,1)

Implementado con la librería `arch`, distribución t -Student (ecuación (2)), retornos escalados por 100 para estabilidad numérica.

Holt-Winters

Estacionalidad aditiva de 365 períodos sobre la serie en niveles. Parámetros por optimización numérica. Pronósticos de 7, 15 y 30 días con intervalos de confianza del 95 % por bootstrap sobre residuos in-sample.

4. Tecnología — Sistemas de Aprendizaje Automático (MLOps)

4.1 Datos

Ingesta *batch* diaria desde la API de XM mediante la librería `pydataxm`, disparada automáticamente por Amazon EventBridge. El script `ingesta_guatape.py` opera de dos formas: *histórico* (primera ejecución, descarga desde 2015-01-01) e *incremental* (ejecuciones posteriores, guiado por el archivo `_metadata/ultima_descarga.txt`). Los datos se almacenan en `s3://pi-2026/data/raw/embalse_guatape/volumen_util_m3/` en formato Parquet particionado por año y mes, manteniendo una copia íntegra y reproducible, siguiendo un proceso de ELT.

4.2 Procesamiento

Preprocesamiento con `pandas` ejecutado como SageMaker Processing Job mediante la imagen `sagemaker-scikit-learn:1.4-2-cpu-py3`. El script `procesamiento_guatape.py` aplica ordenamiento cronológico, deduplicación e interpolación lineal para el único día faltante identificado en el EDA (2015-12-31). El resultado se almacena en `s3://pi-2026/data/curated/` con dos columnas: *fecha* y *volumen_m3*, en formato Parquet.

4.3 Entrenamiento

El entrenamiento se orquesta mediante un SageMaker Pipeline (`pipeline-guatape`) con 11 steps encadenados: ingesta, procesamiento, cuatro ramas de entrenamiento en paralelo (ARIMA, ARMA-GARCH(1,1), Holt-Winters, LSTM), sus correspondientes cuatro steps de inferencia, y finalmente la generación del dashboard.

- **Modelos estadísticos:** ARIMA con $d = 1$ seleccionado por `auto_arima` (criterio AIC), ARMA-GARCH(1,1) sobre retornos logarítmicos con distribución *t*-Student, y Holt-Winters con estacionalidad aditiva de 365 períodos. Los tres generan pronósticos de 7, 15 y 30 días con intervalos de confianza del 95 %.
- **Modelo LSTM:** arquitectura de dos capas apiladas, ventana de 30 días, split 80/20, *early stopping* con paciencia de 20 épocas. Inferencia con Monte Carlo Dropout.

4.4 Almacenamiento

- `s3://pi-2026/data/raw/` — datos crudos extraídos diariamente desde la API de XM, particionados por año y mes en formato Parquet.
- `s3://pi-2026/data/curated/` — serie limpia e imputada lista para entrenamiento.

- `s3://pi-2026/predictions/` — pronósticos de cada modelo (ARIMA, GARCH, HW, LSTM) a 7, 15 y 30 días, en formato Parquet, versionados bajo `latest/` y `versions/<fecha>/`.
- `s3://pi-2026/models/` — artefactos de modelo (`.pkl` para ARIMA, GARCH y HW; `.keras` y `.pkl` para LSTM), con métricas y metadata en JSON, versionados.
- `s3://pi-2026-dashboard-*/` — dashboard HTML público con visualizaciones interactivas, actualizado al finalizar cada ejecución.

4.5 Despliegue

Cada modelo se ejecuta como SageMaker Processing Job con la imagen `sagemaker-scikit-learn:1.4` en instancias `ml.t3.medium`. Los jobs se encadenan mediante SageMaker Pipelines, disparado automáticamente por Amazon EventBridge todos los días a las 12pm hora Colombia. Al finalizar cada ejecución, Amazon SNS envía una notificación por correo electrónico con el estado del pipeline.

4.6 Aplicación

Los resultados se consumen a través de un dashboard HTML estático alojado en Amazon S3 con acceso público. El dashboard muestra:

- Serie histórica de volumen con filtros temporales (1 semana, 1 mes, 1 año, 5 años).
- Pronósticos de los cuatro modelos con sus intervalos de confianza al 95 %.
- Gráfica comparativa entre modelos a 7, 15 y 30 días.
- Métricas de evaluación (MAE, RMSE, MAPE train/test) de cada modelo.

El contenido se regenera automáticamente como último step del pipeline diario.

5. Resultados

5.1 Red Neuronal Convolutacional sobre imágenes Sentinel-2

EfficientNet-B0 produjo R^2 negativo sobre 541 imágenes NDWI. Un perceptrón multicapa alternativo con el área de agua en km^2 como única variable también produjo $R^2 = -0,25$. El diagnóstico identificó dos causas raíz:

- **Limitación conceptual.** El NDWI captura área superficial (km^2), no volumen. La conversión requiere batimetría específica no contenida en la imagen (ecuación (8)). Un modelo multi-embalse no puede generalizar porque la curva área-volumen es única en cada caso.
- **Limitación operacional.** Los filtros de nubosidad operan a nivel de escena. Nubes parciales sobre el espejo de agua reducen artificialmente el área calculada, introduciendo ruido sistemático.

Ante estos resultados, el componente de imágenes satelitales fue descartado del modelo final.

5.2 Modelos estadísticos

ARIMA, ARMA-GARCH(1,1) y Holt-Winters generan pronósticos de 7, 15 y 30 días con intervalos de confianza del 95 %. Evaluados sobre el 20 % final de la serie (split cronológico), los resultados *out-of-sample* se resumen en la tabla 2.

Cuadro 2: Métricas out-of-sample de los modelos estadísticos (test 20 %)			
Modelo	MAE (Mm^3)	RMSE (Mm^3)	MAPE (%)
Holt-Winters	2.55	4.06	0.57
ARMA-GARCH(1,1)	28.21	34.13	6.18
ARIMA	83.76	95.27	18.12

Holt-Winters supera ampliamente a los demás modelos estadísticos gracias a su modelado explícito de la estacionalidad anual de 365 períodos. ARMA-GARCH añade valor en la estimación de intervalos al capturar la varianza condicional no constante. ARIMA, al ser lineal y sin componente estacional, no logra capturar los ciclos hidrológicos anuales del embalse.

5.3 Red Neuronal Recurrente LSTM

El modelo LSTM fue entrenado con TensorFlow/Keras sobre la serie completa disponible hasta la fecha de ejecución, con split 80/20 cronológico. Los resultados *out-of-sample* se presentan en la tabla 3.

El LSTM ocupa el segundo lugar entre los cuatro modelos, superado únicamente por Holt-Winters. La estimación de intervalos de confianza al 95 % se realiza mediante Monte Carlo Dropout con 200 trayectorias. La arquitectura univariada captura adecuadamente la inercia y los ciclos estacionales del embalse dentro del horizonte de corto plazo evaluado.

Cuadro 3: Comparativo de métricas out-of-sample — todos los modelos (test 20 %)

Modelo	MAE (Mm ³)	RMSE (Mm ³)	MAPE (%)	Ranking
Holt-Winters	2.55	4.06	0.57	1
LSTM	5.92	7.51	0.95	2
ARMA-GARCH(1,1)	28.21	34.13	6.18	3
ARIMA	83.76	95.27	18.12	4

Limitaciones

El modelo es univariado y no incorpora variables exógenas (precipitación, caudales de afluentes). El horizonte máximo de 30 días es adecuado a corto plazo pero no cubre horizontes estacionales.

6. Conclusiones

El proyecto logró diseñar e implementar un sistema predictivo completo para la estimación del volumen útil del embalse de El Peñol-Guatapé, integrando modelos estadísticos clásicos y aprendizaje profundo dentro de un pipeline de MLOps desplegado en AWS. La evaluación comparativa sobre datos reales demuestra que Holt-Winters con estacionalidad aditiva de 365 períodos es el modelo más preciso (MAPE 0.57 %), seguido por LSTM (MAPE 0.95 %), ARMA-GARCH(1,1) (MAPE 6.18 %) y ARIMA (MAPE 18.12 %). La superioridad de Holt-Winters refleja la importancia de modelar explícitamente la estacionalidad anual característica de las series hidrológicas colombianas. El pipeline corre automáticamente todos los días mediante Amazon EventBridge, reentrenando los modelos con datos actualizados de la API pública de XM y actualizando un dashboard interactivo accesible públicamente.

Aportes del proyecto

El proyecto demuestra que es posible construir un sistema de monitoreo predictivo de bajo costo para embalses hidroeléctricos usando exclusivamente datos públicos y servicios cloud. La integración de cuatro modelos con horizontes de 7, 15 y 30 días permite combinar la precisión de corto plazo del LSTM con la interpretabilidad estadística de Holt-Winters. El pipeline de MLOps garantiza reproducibilidad, trazabilidad y actualización automática diaria sin intervención manual.

Posibles mejoras

- Incorporar variables exógenas (precipitación, caudales) al modelo LSTM.
- Extender el horizonte mediante arquitecturas *encoder-decoder* o Transformers.

- Explorar datos batimétricos para retomar el componente satelital válidamente.
- Replicar el pipeline a otros embalses del sistema interconectado nacional.

Trabajo futuro

Incorporar variables exógenas (precipitación, caudales de afluentes, índices climáticos como ENSO) al modelo LSTM para mejorar la precisión en horizontes mayores. Explorar arquitecturas *encoder-decoder* o Transformers para pronósticos estacionales. Incorporar datos batimétricos para retomar el componente satelital de forma conceptualmente válida. Replicar el pipeline a otros embalses del sistema interconectado nacional con mínimas modificaciones a los scripts de ingesta.

Referencias

- [1] Z. Liu et al., “A ConvNet for the 2020s,” *IEEE/CVF CVPR*, pp. 11976–11986, 2022.
- [2] D. Hendrycks y K. Gimpel, “Gaussian Error Linear Units (GELUs),” *arXiv:1606.08415v5*, 2023.
- [3] J. Jin et al., “A Comprehensive Survey of Time Series Forecasting,” *arXiv:2411.05793*, 2024.
- [4] M. Jin et al., “Foundation Models for Time Series Analysis,” *arXiv:2403.14735*, 2024.
- [5] Microsoft, “Team Data Science Process Lifecycle.” <https://github.com/Azure/Microsoft-TDSP/blob/master/Docs/lifecycle-detail.md>
- [6] S. Hochreiter y J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, 9(8), 1735–1780, 1997.
- [7] R. F. Engle, “Autoregressive Conditional Heteroscedasticity,” *Econometrica*, 50(4), 987–1007, 1982.
- [8] C. C. Holt, “Forecasting Seasonals and Trends,” *Int. J. Forecasting*, 20(1), 5–10, 2004.